

PROYECTO DE APRENDIZAJE ESTADÍSTICO

La química de la calidad

Predicción de la calidad del vino tinto
a partir de sus propiedades fisicoquímicas

Omar Mendoza · Carlos Nieves
Laboratorio de Aprendizaje Estadístico
21 de septiembre de 2026



Objetivos

Objetivo general

Analizar qué propiedades fisicoquímicas del vino tinto se asocian con su calidad, comparando modelos de regresión con y sin regularización, para identificar los factores significativos y ver qué tanto se puede predecir.

Objetivos específicos

- 1 Describir el dataset y sus transformaciones.
- 2 Proponer tres modelos: completo, con interacción y polinomial.
- 3 Ajustar cada uno sin penalización, Ridge, Lasso y Elastic Net.
- 4 Revisar los seis problemas con los residuos.
- 5 Comparar las doce versiones con R^2 .
- 6 Evaluar la significancia de los factores.

Qué buscamos explicar

¿Hasta dónde las mediciones de laboratorio permiten estimar la calidad del vino?

1,599

vinos tintos Vinho Verde
(UCI, Cortez et al., 2009)

11

propiedades fisicoquímicas
medidas en laboratorio

3 – 8

calidad observada
(escala 0 a 10)


¿Qué es la calidad?

- Mediana de la nota de al menos 3 catadores expertos (cata a ciegas).
- Subjetiva, entera y con pocos valores.
- La química se mide en laboratorio: objetiva y barata.

Así se ve el dataset

winequality-red.csv · 1,599 renglones × 12 columnas · sin faltantes · 240 duplicados


fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5
7.8	0.88	0	2.6	0.098	25	67	0.9968	3.2	0.68	9.8	5
7.8	0.76	0.04	2.3	0.092	15	54	0.997	3.26	0.65	9.8	5
11.2	0.28	0.56	1.9	0.075	17	60	0.998	3.16	0.58	9.8	6
7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5




- 11 variables numéricas continuas y quality entera.
- Cinco con cola larga a la derecha → log.
- Unidades muy distintas (density ≈ 1 , SO₂ hasta 289) → escalar.

La mayoría de los vinos son 5 o 6

Distribución de la calidad y correlación de cada factor con ella




82.5 % son 5 o 6. Muy pocos en los extremos.



- alcohol +0.48 y sulphates +0.25 suben la calidad; volatile acidity -0.39 la baja.
- Factores correlacionados entre sí (fixed acidity, citric acid, density, pH) → colinealidad.

El análisis de residuos justificó el logaritmo


Diagnóstico del modelo con los 11 factores crudos, antes de transformar nada



- Sin curva ni embudo. Las bandas son por quality entera.
- **Puntos palanca: máx 0.13 vs promedio 0.0126, en las variables sesgadas.**
- Solución: $\log(x)$ en las 5. Palanca máxima baja a 0.078.
- VIF alto: fixed acidity (8.1) y density (7.3) $\rightarrow$ fuera de M2 y M3.

Pipeline del proyecto

Mismo tratamiento para entrenamiento y prueba; lo que aprende de los datos se ajusta solo con train



Ridge $\alpha = 1$ · Lasso y Elastic Net $\alpha = 0.01$ · Partición 70/30, semilla 42

Tres modelos, doce ajustes

Cada modelo se ajusta sin penalización, con Ridge, con Lasso y con Elastic Net

M1 · Todos los factores

11 términos.

Las once propiedades, con log y escalamiento.

Modelo base.

M2 · Interacción

7 términos.

6 factores significativos + alcohol $\times$ log(sulphates).

El efecto del alcohol depende de los sulfatos.

M3 · Polinomial

5 términos.


3 factores + alcohol² y log(sulphates)².

El efecto se aplanan en valores altos.

Las transformaciones salen del análisis de residuos y de las pruebas de hipótesis.

Modelo 1: siete factores significativos, cuatro no

Prueba $H_0: \beta_j = 0$ con $\alpha = 0.05$ sobre el modelo sin penalización




0.392

R^2 de prueba (train 0.358)

- Significativos (7): alcohol, sulphates, volatile acidity, total SO_2 , pH, chlorides, free SO_2 .
- No significativos (4): fixed acidity, citric acid, residual sugar, density.
- Los más fuertes: alcohol (+), sulphates (+), volatile acidity (-).

La regularización solo ayudó en el modelo 1

Coeficientes de M1 en sus cuatro versiones



- Ridge: casi no cambia nada.
- **Lasso apaga fixed acidity, citric acid y density. R^2 test 0.392 $\rightarrow$ 0.398.**
- Elastic Net apaga dos.
- En M2 y M3 las cuatro versiones empatan: no hay nada que quitar.

Modelo 2: alcohol y sulfatos se refuerzan

Seis factores más la interacción alcohol $\times$ log(sulphates); todo significativo

Sulfatos bajos

log(sulfatos) a -2 DE de su media

+0.155

puntos de calidad por +1 DE de alcohol

Sulfatos altos

log(sulfatos) a +2 DE de su media


+0.424

puntos de calidad por +1 DE de alcohol

- Única interacción significativa de 6 probadas ($p = 0.0023$).
- R^2 test 0.416, el mejor. Train 0.359: sin sobreajuste.
- VIF entre 1.1 y 1.4: sin colinealidad.

Modelo 3: el efecto de alcohol y sulfatos se aplanan

Polinomial con cinco columnas: alcohol, alcohol², log(sulphates), log(sulphates)², volatile acidity



- **Cuadráticos significativos y negativos ($p = 0.006$ y 0.0005).**
- Sulfatos: ayudan hasta cierto punto, luego se aplanan.
- Alcohol: casi recta, curva leve hacia abajo.
- R^2 test 0.409 con solo 5 columnas.

VIF todos abajo de 2.

M2 obtuvo el mayor R^2 de prueba


Misma partición para los doce ajustes; en ningún modelo el test sale peor que el train

Modelo	Sin penalización	Ridge	Lasso	Elastic Net
M1 · 11 términos	0.3921	0.3923	0.3982	0.3963
M2 · 7 términos	0.4157	0.4157	0.4151	0.4155
M3 · 5 términos	0.4089	0.4090	0.4099	0.4097

R^2 de prueba


- Los tres explican $\approx 40\%$ de la varianza de la calidad.
- M2: el mejor y el más simple.
- Lasso mejora M1; en M2 y M3 empata.

R^2 en entrenamiento y prueba



Los residuos del modelo 2 quedan limpios

Los seis problemas de una regresión, revisados sobre el modelo con interacción



- ✓ **Linealidad:** sin curva (las bandas son por quality entera)
- ✓ **Correlación de errores:** ≈ 0.01 , no hay
- ✓ **Varianza:** pareja
- ✓ **Atípicos:** 4, vinos con nota 3 u 8
- ✓ **Palanca:** resuelta con el log ($0.13 \rightarrow 0.07$)
- ✓ **Colinealidad:** VIF entre 1.10 y 1.40

Conclusiones

Respecto a cada objetivo planteado

- 1 Dataset** 240 duplicados fuera. Log en 5 variables sesgadas, justificado por los puntos palanca del modelo crudo.
- 2 Modelos** M2 (6 factores + alcohol $\times$ sulfatos) fue el mejor: $R^2 = 0.416$, sin colinealidad, todo significativo.
- 3 Residuos** Colinealidad y palanca aparecieron y se resolvieron. Los otros cuatro problemas no.
- 4 R^2** Explicamos $\approx 40\%$ de la varianza de la calidad. Es una nota subjetiva con 6 valores. La regularización solo ayudó en M1.
- 5 Significancia** Suben la calidad: alcohol y sulfatos. La bajan: acidez volátil, SO_2 total, cloruros y pH.

Correcciones después de la presentación

Dos precisiones que se hicieron en la exposición y ya quedaron corregidas

1 · Qué explica el R^2

Se dijo: “el modelo explica el 40 % de la calidad”. **Correcto:** el R^2 es la proporción de la **varianza** de la calidad que explica el modelo. M2 explica el 41.6 % de la varianza de la calidad en prueba; el 58.4 % restante queda en los residuos.

2 · Sesgo: el que pedía la pregunta es el del intercambio sesgo–varianza

Se respondió con el sesgo (asimetría) de las variables: chlorides 5.5, residual sugar 4.6, sulphates 2.4, total y free SO_2 1.5 y 1.2, que el logaritmo bajó a menos de 2. **Lo que se preguntaba** era el sesgo del modelo: la regularización agrega un poco de sesgo a cambio de reducir varianza.

Modelo 1	R^2 train	R^2 test	Lectura
OLS (insesgado)	0.3582	0.3921	ajusta lo más pegado a train, con más varianza
Lasso ($\alpha = 0.01$)	0.3554	0.3982	train baja = sesgo agregado · test sube = varianza reducida

Referencias

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Wine Quality [Data set]. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/186/wine+quality>

Notebook y dataset: github.com/Omarcianopk2/proyecto-calidad-vino-tinto

¡Gracias!