



ITESO, Universidad
Jesuita de Guadalajara

Laboratorio de Aprendizaje Estadístico

Proyecto 1

Predicción de la calidad del vino tinto a partir de sus propiedades fisicoquímicas mediante modelos de regresión

Integrantes

Omar Mendoza - 757806

Carlos Nieves - 758210

Profesor: Gabriel Alejandro Morales Ruiz

21 de septiembre de 2026

Índice

Objetivos	3
Marco teórico.....	4
Análisis del dataset	7
Modelo propuesto	11
Pipeline	14
Ajuste de modelos y comparación de R^2	16
Análisis de significancia de factores.....	18
Conclusiones	21
Fuente del dataset	21

Objetivos

Objetivo general

Analizar qué propiedades fisicoquímicas del vino tinto Vinho Verde se asocian con la calidad que le asignan los catadores, construyendo y comparando modelos de regresión con y sin regularización, para identificar los factores significativos y evaluar qué tanto se puede predecir la calidad a partir de mediciones de laboratorio.

Objetivos específicos

1. Describir el dataset Wine Quality (vino tinto): su origen, sus 11 variables fisicoquímicas y la variable de calidad, y detectar qué limpieza y transformaciones necesita antes de usarse en una regresión.
2. Proponer tres modelos de regresión distintos: uno con todos los factores, uno con interacción entre factores y uno polinomial.
3. Ajustar cada modelo en cuatro versiones: sin penalización, con Ridge, con Lasso y con Elastic Net, aplicando limpieza, transformación, escalamiento y partición train-test.
4. Analizar los residuos de cada modelo para revisar los seis problemas comunes de una regresión y hacer las transformaciones que salgan de ese análisis.
5. Comparar el desempeño de las doce versiones a través del R^2 en entrenamiento y en prueba.
6. Evaluar la significancia estadística de los factores en los modelos sin penalización para determinar cuáles propiedades tienen evidencia de afectar la calidad del vino.

Marco teórico

Regresión lineal

La regresión lineal modela la relación entre una variable dependiente Y y una o más variables independientes $X_1, \dots, X_p$ suponiendo que esa relación es lineal en los parámetros:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p + \varepsilon$$

donde β_0 es el intercepto, cada β_j es el cambio esperado en Y por cada unidad que sube X_j manteniendo lo demás fijo, y ε es el error aleatorio. Los coeficientes se estiman por mínimos cuadrados ordinarios (OLS), que busca los valores de β que minimizan la suma de residuos al cuadrado:

$$RSS = \sum_i (y_i - \hat{y}_i)^2$$

Qué tan bien ajusta el modelo se mide con el R^2 , que es la proporción de la varianza de Y que el modelo logra explicar. Va de 0 a 1 y entre más alto mejor, aunque siempre sube al agregar factores; por eso se compara también en datos de prueba que el modelo no vio.

Regresión polinomial

Cuando la relación entre X y Y no es una recta sino una curva, se puede seguir usando regresión lineal agregando potencias de la variable como nuevos factores:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \dots + \beta_d X^d + \varepsilon$$

El modelo sigue siendo lineal en los parámetros, así que se ajusta igual con OLS. Lo que cambia es que ahora puede capturar curvatura. El riesgo es usar un grado muy alto, porque el polinomio empieza a seguir el ruido de los datos y pierde capacidad de generalizar (sobreajuste). En la práctica grados 2 o 3 suelen ser suficientes.

Interacción de factores

Hay interacción cuando el efecto de un factor sobre Y depende del nivel de otro factor. En un modelo aditivo cada β_j es fijo, pero si se agrega el producto de dos variables:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 (X_1 \times X_2) + \varepsilon$$

el efecto de X_1 pasa a ser $\beta_1 + \beta_3 X_2$, o sea que cambia según el valor de X_2 . Si β_3 sale significativo hay evidencia de que los dos factores no actúan por separado. Por el principio de jerarquía, si se incluye la interacción también se dejan los efectos principales aunque no sean significativos.

Significancia de factores

Para saber si un factor de verdad afecta a Y , o si su coeficiente pudo salir distinto de cero por azar, se hace una prueba de hipótesis por cada coeficiente:

$$H_0: \beta_j = 0 \quad H_1: \beta_j \neq 0$$

El estadístico de prueba es $t = \hat{\beta}_j / SE(\hat{\beta}_j)$, que compara el tamaño del coeficiente contra su error estándar. De ahí sale el p-value, que es la probabilidad de ver un coeficiente así de grande si en realidad fuera cero. Si el p-value es menor al nivel de significancia $\alpha = 0.05$ se rechaza H_0 y se dice que el factor es significativo. Un factor significativo no necesariamente tiene un efecto grande, solo tiene un efecto que no parece ser cero.

Regularización (Ridge, Lasso y Elastic Net)

La regularización agrega a la función de costo una penalización sobre el tamaño de los coeficientes. Con eso el modelo solo deja crecer un coeficiente si eso reduce el error lo suficiente, lo cual sacrifica un poco de sesgo pero reduce la varianza y ayuda a generalizar, sobre todo cuando hay muchos factores o están correlacionados entre sí.

Ridge usa penalización L2, la suma de los coeficientes al cuadrado:

$$RSS_L2 = \sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j \beta_j^2$$

Encoge los coeficientes hacia cero pero nunca los hace exactamente cero.

Lasso usa penalización L1, la suma de los valores absolutos:

$$RSS_L1 = \sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j |\beta_j|$$

Con L1 sí hay coeficientes que llegan a cero exacto, así que Lasso además selecciona variables.

Elastic Net combina las dos penalizaciones con un parámetro ρ que reparte el peso entre L1 y L2:

$$RSS_EN = \sum_i (y_i - \hat{y}_i)^2 + \lambda [\rho \sum_j |\beta_j| + (1 - \rho) \sum_j \beta_j^2]$$

En los tres casos λ (que en sklearn se llama alpha) controla qué tan fuerte es la penalización. Como la penalización depende del tamaño de los coeficientes, y ese tamaño depende de las unidades de cada factor, antes de regularizar se deben estandarizar las variables.

Seis problemas comunes en una regresión

Los supuestos del modelo lineal se revisan con los residuos $e_i = y_i - \hat{y}_i$. Los seis problemas que se buscan son:

1. **No linealidad.** La relación real no es una recta. Se ve en la gráfica de residuos contra valores ajustados: si hay un patrón curvo el modelo lineal se queda corto.
2. **Correlación de los errores.** Los residuos no son independientes entre sí, típico en datos en el tiempo. Infla la confianza en los coeficientes.
3. **Varianza no constante.** El tamaño de los residuos cambia según el nivel del ajustado (heterocedasticidad). Se ve como un embudo en la gráfica de residuos.
4. **Valores atípicos.** Observaciones cuya y queda muy lejos de lo que predice el modelo. Se detectan con residuos estandarizados mayores a 3 en valor absoluto.

5. **Puntos palanca.** Observaciones con valores raros en las x , que jalan la regresión más que las demás. Se miden con la palanca h_i , que se compara contra su promedio $(p+1)/n$.
6. **Colinealidad.** Dos o más factores traen casi la misma información, lo que infla los errores estándar y vuelve inestables los coeficientes. Se mide con el factor de inflación de varianza $VIF_j = 1 / (1 - R^2_j)$; arriba de 5 o 10 ya es serio.

Tema del proyecto: calidad del vino tinto

La calidad de un vino se decide en una cata sensorial, que es cara, lenta y subjetiva. Las propiedades fisicoquímicas en cambio se miden en laboratorio de forma objetiva y barata. La pregunta que se quiere responder es hasta dónde esas mediciones (acidez, azúcar, sulfitos, alcohol, pH, etc.) explican la calificación que dan los catadores. Los autores del dataset trabajaron este mismo problema con varios métodos de minería de datos; aquí se aborda con regresión lineal, sus extensiones y regularización, que es lo visto en el curso.

Análisis del dataset

¿De dónde viene?

El dataset Wine Quality está en el UCI Machine Learning Repository, uno de los repositorios públicos de datasets más usados para investigación en aprendizaje automático. Fue creado en 2009 por Paulo Cortez de la Universidad de Minho junto con la Comisión de Viticultura de la Región de los Vinhos Verdes (CVRVV) en Portugal, para el artículo Modeling wine preferences by data mining from physicochemical properties. Hay dos archivos, uno de vino tinto y uno de vino blanco; en este proyecto se usa solo el tinto.

¿Qué contiene?

Son 1599 muestras de vino tinto Vinho Verde. Para cada una hay 11 variables fisicoquímicas medidas en laboratorio y una calificación de calidad de 0 a 10 que es la mediana de al menos tres catadores expertos. Por privacidad no hay marca, tipo de uva ni precio, solo lo que se midió.

Variable	Qué es	Unidad
fixed acidity	Acidez fija, principalmente ácido tartárico	g/dm ³
volatile acidity	Acidez volátil, ácido acético. Mucha da sabor a vinagre	g/dm ³
citric acid	Ácido cítrico, da frescura	g/dm ³
residual sugar	Azúcar que queda después de la fermentación	g/dm ³
chlorides	Sales, cloruro de sodio	g/dm ³
free sulfur dioxide	SO ₂ libre, protege contra microbios y oxidación	mg/dm ³
total sulfur dioxide	SO ₂ total, libre más ligado	mg/dm ³
density	Densidad, depende del alcohol y el azúcar	g/cm ³
pH	Qué tan ácido es, casi todos entre 3 y 4	—
sulphates	Sulfatos, aditivo antimicrobiano	g/dm ³
alcohol	Grado alcohólico	% vol
quality	Calificación sensorial de los catadores	0 a 10

¿Qué información dan las muestras?

Cada renglón es un vino distinto con su análisis químico completo y su calificación. No hay orden en el tiempo ni relación entre renglones; cada muestra es independiente. Todas las variables son numéricas continuas menos quality, que es entera y en la práctica solo va de 3 a 8. La mayoría de los vinos están calificados con 5 o 6, hay muy pocos malos (3 y 4) y muy pocos excelentes (7 y 8), o sea que las clases están desbalanceadas.




Figura 1. Distribución de la calidad en las 1599 muestras.

¿Qué se quiere analizar?

Se quiere saber qué propiedades químicas se asocian con que un vino sea mejor o peor calificado, cuáles no aportan, si hay factores que interactúan entre sí o que tienen efecto curvo, y qué tanto se puede predecir la calidad con un modelo lineal. También se compara si regularizar ayuda o no.

La exploración inicial confirma lo esperado: alcohol es lo que más se relaciona con la calidad (correlación 0.48) y volatile acidity lo que más resta (-0.39). También aparecen pares muy correlacionados entre factores: fixed acidity con citric acid y con density (0.67), free con total sulfur dioxide (0.67), y fixed acidity contra pH (-0.68), lo que anticipa colinealidad.




Figura 2. Matriz de correlación entre las 12 variables.

¿Qué variables se tienen que transformar?

Todas las variables ya son numéricas, así que no hay que codificar categorías. Lo que sí necesita el dataset es:

- **Quitar duplicados.** Hay 240 renglones exactamente repetidos; son el mismo vino cargado dos veces y darían peso doble. Quedan 1359.
- **Transformación logarítmica** en las variables muy sesgadas a la derecha: chlorides (sesgo 5.5), residual sugar (4.55), sulphates (2.41), total sulfur dioxide (1.54) y free sulfur dioxide (1.23). Tienen colas largas que producen puntos palanca; el logaritmo las compacta. Ninguna tiene ceros (el mínimo de chlorides es 0.012), así que se aplica $\log(x)$ directo.
- **Estandarización** con StandardScaler ajustado solo en entrenamiento, porque las unidades son muy distintas (densidad ~ 0.99 contra sulfitos hasta 289) y la regularización lo necesita.
- **Partición** 70/30 en entrenamiento y prueba con semilla fija (42) para que sea reproducible.

¿Qué resultado se podría encontrar?

Por lo que se sabe del vino, se espera que el alcohol y los sulfatos se asocien positivamente con la calidad y que la acidez volátil (sabor a vinagre) se asocie negativamente. También se espera que el R^2 sea moderado, porque la calidad es una calificación subjetiva con solo seis valores posibles y la química no lo explica todo. Y como varias variables miden cosas parecidas (las dos acideces, los dos SO_2 , densidad contra alcohol y azúcar), probablemente haya algo de colinealidad.

Modelo propuesto

Se definen tres modelos distintos para comparar entre ellos. Cada uno se ajusta en cuatro versiones: sin penalización (OLS), con Ridge ($\alpha = 1$), con Lasso ($\alpha = 0.01$) y con Elastic Net ($\alpha = 0.01, \rho = 0.5$). Los alphas se eligen con un barrido sobre el modelo 1 mirando el R^2 de prueba; se usan los mismos en los tres modelos para que la comparación sea justa.

Transformaciones a partir del análisis de residuos

Antes de transformar nada se ajustó el modelo con los 11 factores tal cual vienen y se revisaron sus residuos. El diagnóstico del modelo crudo (Figura 3) mostró:

- No linealidad: sin patrón curvo. Las bandas diagonales que se ven no son un problema del modelo, son porque quality solo toma valores enteros.
- Varianza: pareja en el centro, un poco mayor en los extremos por el mismo motivo.
- Atípicos: algunos vinos con residuo estandarizado fuera de ± 3 , casi todos calificados con 3 u 8.
- Puntos palanca: varios puntos muy separados a la derecha, palanca máxima 0.13 contra un promedio de 0.0126. Son los vinos con valores extremos en chlorides, residual sugar o sulphates, justo las variables con sesgo mayor a 2. Esto es lo que motivó la transformación logarítmica.
- Colinealidad: fixed acidity (VIF 8.06) y density (6.12) por su relación con citric acid, pH y alcohol.
- Correlación de errores: prácticamente cero, como se espera de muestras independientes.




Figura 3. Diagnóstico de residuos del modelo con factores crudos.

Con base en eso se aplicó $\log(x)$ a las cinco variables sesgadas. El sesgo bajó en todas: total y free sulfur dioxide quedaron casi simétricas (-0.08 y -0.22), sulphates bajó de 2.41 a 0.96, y chlorides y residual sugar bajaron de 5.5 y 4.55 a 1.89 y 1.77. Con eso la palanca máxima del modelo 1 cayó de 0.13 a 0.078.




Figura 4. Variables sesgadas antes y después del logaritmo.

Modelo 1: todos los factores

Es el modelo base, con los 11 factores sin interacciones ni polinomios.

$$\text{quality} = \beta_0 + \beta_1(\text{fixed acidity}) + \beta_2(\text{volatile acidity}) + \beta_3(\text{citric acid}) + \beta_4(\log \text{residual sugar}) + \beta_5(\log \text{chlorides}) + \beta_6(\log \text{free SO}_2) + \beta_7(\log \text{total SO}_2) + \beta_8(\text{density}) + \beta_9(\text{pH}) + \beta_{10}(\log \text{sulphates}) + \beta_{11}(\text{alcohol}) + \varepsilon$$

Su diagnóstico de residuos (ya con las variables transformadas) deja fixed acidity y density con VIF de 8.10 y 7.25, arriba del umbral de 5. Por eso esos dos factores se excluyen de los modelos 2 y 3.

Modelo 2: factores significativos con interacción

Se toman solo los seis factores que resultan significativos en el modelo 1 y no tienen VIF alto, y se agrega la interacción entre alcohol y sulphates. La idea es que el efecto del alcohol sobre la calidad puede depender del nivel de sulfatos, que es un conservador que afecta cómo se percibe el vino. Se probaron seis interacciones candidatas sobre el modelo 1 y esta fue la única significativa ($p = 0.0023$).

$$\text{quality} = \beta_0 + \beta_1(\text{alcohol}) + \beta_2(\text{volatile acidity}) + \beta_3(\log \text{sulphates}) + \beta_4(\log \text{total SO}_2) + \beta_5(\log \text{chlorides}) + \beta_6(\text{pH}) + \beta_7(\text{alcohol} \times \log \text{sulphates}) + \varepsilon$$

En su diagnóstico todos los VIF quedan entre 1.10 y 1.40; la colinealidad desapareció. Como las variables se estandarizan antes de multiplicarse, la interacción no infla el VIF de sus componentes.

Modelo 3: polinomial

Se toman los tres factores más fuertes y se agregan los términos cuadráticos de alcohol y sulphates, que fueron los que mostraron curvatura significativa al probarlos por separado (p del término cuadrático: 0.0018 y < 0.0001). Se conserva volatile acidity lineal.

$$\text{quality} = \beta_0 + \beta_1(\text{alcohol}) + \beta_2(\text{alcohol})^2 + \beta_3(\log \text{ sulphates}) + \beta_4(\log \text{ sulphates})^2 + \beta_5(\text{volatile acidity}) + \varepsilon$$

Los VIF entre los términos cuadráticos y sus lineales suben un poco, lo normal en un polinomio, pero se mantienen abajo de 2. La palanca muestra los vinos con alcohol o sulfatos extremos, que al elevarse al cuadrado se separan más.

Pipeline

El flujo completo del proyecto sigue el esquema visto en clase: del dataset se hace el EDA, de ahí salen X y y , X pasa por la ingeniería de características para obtener X^* , con X^* y y se ajusta la regresión (con su α cuando hay penalización) y se obtiene el modelo entrenado. Con el modelo se predice $\hat{y}$, se calculan los residuos $\varepsilon = y - \hat{y}$ para el análisis de residuos, y se revisa la significancia estadística de los coeficientes. Los datos nuevos (X_{new} , que aquí es el conjunto de prueba) pasan por la misma ingeniería de características ya ajustada antes de predecir. Todo lo que va de la ingeniería de características al ajuste es el pipeline del proyecto.




Figura 5. Pipeline del proyecto.

Paso por paso, adaptado a este proyecto:

1. **Dataset.** Se lee winequality-red.csv (separado por punto y coma): 1599 renglones y 12 columnas.
2. **EDA.** Se revisan el tipo y la distribución de cada variable, el sesgo, las correlaciones y los valores extremos; se detectan 240 duplicados (se eliminan, quedan 1359) y 0 faltantes; se plantea la hipótesis de que el alcohol suma y la acidez volátil resta.
3. **Transformación.** Se aplica $\log(x)$ a chlorides, residual sugar, sulphates, total sulfur dioxide y free sulfur dioxide. Es una transformación fija que no aprende nada de los datos, por eso se hace antes de partir.
4. **X, y y train-test split.** X son los 11 factores y y es quality. Se parte 70 % entrenamiento (951 vinos) y 30 % prueba (408) con `random_state = 42`.
5. **Escalamiento.** StandardScaler ajustado solo con el conjunto de entrenamiento y aplicado al de prueba con esas mismas medias y desviaciones, para que la información del test no se filtre al modelo.
6. **Construcción de X^* .** Sobre las variables ya escaladas se arman las tres matrices: todas las columnas (M1), subconjunto más la columna de interacción (M2) y subconjunto más las columnas al cuadrado (M3).
7. **Ajuste.** Para cada X^* se ajustan OLS (statsmodels, con columna de unos), Ridge ($\alpha = 1$), Lasso y Elastic Net (sklearn, $\alpha = 0.01$).
8. **Modelo entrenado $\rightarrow$ significancia estadística.** Con el OLS se prueba $H_0: \beta_j = 0$ por factor con $\alpha = 0.05$.
9. **Predict $\rightarrow \hat{y} \rightarrow$ residuos.** Se predice en entrenamiento y en prueba, se calcula el R^2 de cada uno, y con los residuos de entrenamiento se hace el análisis de los seis problemas (no linealidad, correlación de errores, varianza, atípicos, palanca y VIF).
10. **Datos nuevos.** El conjunto de prueba pasa por el mismo escalador ya ajustado y por la misma construcción de X^* antes de predecir.

Ajuste de modelos y comparación de R^2

Elección de alpha

Antes de ajustar se hizo un barrido de alpha sobre el modelo 1 mirando el R^2 de prueba y cuántos coeficientes se van a cero:

alpha	Ridge R^2 test	Lasso R^2 test	Lasso ceros	ENet R^2 test	ENet ceros
0.001	0.3921	0.3947	0	0.3935	0
0.01	0.3921	0.3982	3	0.3963	2
0.05	0.3921	0.3876	5	0.3962	5
0.1	0.3921	0.3537	8	0.3831	5
0.5	0.3922	0.0000	11	0.1464	9
1	0.3923	0.0000	11	0.0000	11
10	0.3939	0.0000	11	0.0000	11

Ridge casi no cambia con alpha porque, con 11 factores estandarizados y 951 observaciones, la penalización L2 tiene poco que hacer; se usa alpha = 1. Lasso y Elastic Net se apagan rápido: Lasso con alpha = 0.5 y Elastic Net con alpha = 1 ya no dejan ningún coeficiente. El mejor R^2 de prueba sale alrededor de alpha = 0.01, donde Lasso quita 3 factores sin perder ajuste, así que ese es el valor que se usa para los dos.

Resultados de las doce versiones

Modelo	Versión	R^2 train	R^2 test	Coef. en 0
Modelo 1	Sin penalización	0.3582	0.3921	0
	Ridge	0.3582	0.3923	0
	Lasso	0.3554	0.3982	3
	Elastic Net	0.3570	0.3963	2
Modelo 2	Sin penalización	0.3587	0.4157	0
	Ridge	0.3587	0.4157	0
	Lasso	0.3577	0.4151	0
	Elastic Net	0.3584	0.4155	0
Modelo 3	Sin penalización	0.3468	0.4089	0
	Ridge	0.3468	0.4090	0
	Lasso	0.3461	0.4099	0
	Elastic Net	0.3466	0.4097	0




Figura 6. R^2 en entrenamiento y prueba por modelo y versión.

Los tres modelos quedan en la misma zona, con R^2 de prueba entre 0.39 y 0.42. El modelo 2 es el mejor en prueba (0.4157) y el más parsimonioso: 7 columnas contra 11 del modelo 1, sin colinealidad y con todos los factores significativos. El modelo 3, con solo 5 columnas, queda casi igual (0.4089), lo que dice que casi toda la información está en alcohol, sulphates y volatile acidity.

En ningún modelo el R^2 de prueba es menor al de entrenamiento; no hay sobreajuste. De hecho el de prueba sale un poco más alto, lo que indica que la partición de prueba resultó ligeramente más fácil de predecir que la de entrenamiento.

La regularización solo ayuda en el modelo 1. Ahí Ridge deja los coeficientes casi iguales; Lasso apaga fixed acidity, citric acid y density (tres de los cuatro factores no significativos) y sube el R^2 de prueba de 0.3921 a 0.3982; Elastic Net apaga dos. En los modelos 2 y 3, que ya vienen depurados, las cuatro versiones salen prácticamente idénticas: cuando todos los factores aportan, no hay nada que penalizar.




Figura 7. Coeficientes del modelo 1 en sus cuatro versiones.

Análisis de significancia de factores

Para cada modelo sin penalización se hizo la prueba $H_0: \beta_j = 0$ contra $H_1: \beta_j \neq 0$ con $\alpha = 0.05$, usando el estadístico t y el p -value que reporta statsmodels.

Modelo 1

Factor	Coeficiente	Error estándar	t	p-value	Significativo
const	5.6246	0.0215	261.24	0.0000	sí
fixed acidity	-0.0312	0.0613	-0.51	0.6112	no
volatile acidity	-0.1670	0.0286	-5.85	0.0000	sí
citric acid	-0.0208	0.0368	-0.57	0.5720	no
residual sugar	-0.0212	0.0287	-0.74	0.4610	no
chlorides	-0.1014	0.0261	-3.88	0.0001	sí
free sulfur dioxide	0.0936	0.0370	2.53	0.0117	sí
total sulfur dioxide	-0.1262	0.0392	-3.22	0.0013	sí
density	0.0425	0.0580	0.73	0.4635	no
pH	-0.1217	0.0399	-3.05	0.0024	sí
sulphates	0.1768	0.0256	6.90	0.0000	sí
alcohol	0.3176	0.0413	7.69	0.0000	sí

Siete factores rechazan H_0 : volatile acidity, sulphates, alcohol, total sulfur dioxide, chlorides, pH y free sulfur dioxide. Los otros cuatro (fixed acidity, citric acid, residual sugar y density) no son significativos; justamente fixed acidity y density son los de VIF más alto, así que su información ya la traen otros factores. Como las variables están estandarizadas, los coeficientes se pueden comparar entre sí: los más grandes en valor absoluto son alcohol (0.318), sulphates (0.177) y volatile acidity (-0.167).




Figura 8. Coeficientes estandarizados del modelo 1; en verde los significativos.

Modelo 2

Factor	Coeficiente	Error estándar	t	p-value	Significativo
const	5.6155	0.0217	258.83	0.0000	sí
alcohol	0.2892	0.0249	11.63	0.0000	sí
volatile acidity	-0.1601	0.0242	-6.61	0.0000	sí
sulphates	0.1925	0.0245	7.86	0.0000	sí
total sulfur dioxide	-0.0592	0.0225	-2.63	0.0087	sí
chlorides	-0.0912	0.0254	-3.59	0.0003	sí
pH	-0.0882	0.0239	-3.69	0.0002	sí
alcohol × sulphates	0.0673	0.0227	2.97	0.0031	sí

Todos los factores son significativos, incluida la interacción. Su coeficiente es positivo: el alcohol sube la calidad y ese efecto se hace más grande conforme hay más sulfatos. Evaluando $\beta_1 + \beta_7 \cdot \text{sulphates}$, el efecto del alcohol vale 0.155 cuando sulphates está dos desviaciones abajo de la media y 0.424 cuando está dos arriba, casi el triple. Los dos factores se refuerzan, no actúan por separado.

Modelo 3

Factor	Coeficiente	Error estándar	t	p-value	Significativo
const	5.7170	0.0301	189.88	0.0000	sí
alcohol	0.3526	0.0279	12.63	0.0000	sí

Factor	Coefficiente	Error estándar	t	p-value	Significativo
alcohol ²	-0.0493	0.0179	-2.75	0.0060	sí
sulphates	0.1991	0.0263	7.57	0.0000	sí
sulphates ²	-0.0431	0.0124	-3.48	0.0005	sí
volatile acidity	-0.1903	0.0232	-8.19	0.0000	sí

Los dos términos cuadráticos son significativos y negativos. sulphates² indica que los sulfatos suben la calidad hasta cierto punto y luego el efecto se aplana o baja, lo que tiene sentido porque en exceso dan sabor. alcohol² también es negativo aunque con menos significancia: la relación es casi recta con una ligera curvatura hacia abajo en los vinos más fuertes.




Figura 9. Efecto cuadrático de alcohol y sulphates sobre la calidad.

Resumen

Modelo	Factores	Significativos	No significativos	R ² train	p-value de F
Modelo 1	11	7	fixed acidity, citric acid, residual sugar, density	0.3582	7.9e-83
Modelo 2	7	7	ninguno	0.3587	1.3e-86
Modelo 3	5	5	ninguno	0.3468	6.3e-85

El estadístico F de los tres modelos tiene p-value prácticamente cero, así que los tres son significativos en conjunto. En los modelos 2 y 3, construidos solo con factores fuertes, todo es significativo incluyendo la interacción y los dos términos cuadráticos.

Conclusiones

El objetivo general era analizar qué propiedades fisicoquímicas se asocian con la calidad del vino tinto y qué tanto se puede predecir esa calidad con regresión. Respecto a cada objetivo específico:

Sobre el dataset (objetivo 1). Las 1599 muestras traían 240 duplicados que se quitaron. Todas las variables eran numéricas, pero cinco tenían sesgo fuerte hacia la derecha y generaban puntos palanca; el análisis de residuos del modelo crudo fue lo que justificó transformarlas con logaritmo. Se estandarizó todo porque la regularización lo requiere.

Sobre los modelos (objetivos 2 y 3). Se construyeron los tres modelos pedidos en sus cuatro versiones. El modelo 2, con seis factores significativos más la interacción alcohol $\times$ sulphates, fue el mejor en prueba ($R^2 = 0.4157$) y el más limpio: sin colinealidad y con todos los factores significativos. El modelo 3 polinomial quedó casi igual (0.4089) con solo cinco columnas.

Sobre los residuos (objetivo 4). De los seis problemas, los que sí aparecieron fueron la colinealidad en el modelo 1 (fixed acidity y density con VIF mayor a 5) y los puntos palanca por las variables sesgadas. El logaritmo resolvió lo segundo y quitar esos dos factores resolvió lo primero. No hubo no linealidad marcada, ni varianza claramente no constante, ni correlación de errores; los atípicos son los vinos calificados con 3 u 8, que son muy pocos y el modelo no alcanza a distinguir.

Sobre el R^2 (objetivo 5). Los tres modelos explican entre 35 % y 42 % de la varianza de la calidad. Es moderado, pero consistente con la naturaleza del problema: la calidad es una calificación subjetiva con solo seis valores posibles y la química no captura todo lo que un catador percibe. La regularización solo ayudó en el modelo 1, donde Lasso apagó los factores inútiles; en modelos ya depurados no cambió nada.

Sobre la significancia (objetivo 6). Las propiedades con evidencia de afectar la calidad son el alcohol y los sulfatos (positivo) y la acidez volátil, el dióxido de azufre total, los cloruros y el pH (negativo). El efecto del alcohol depende del nivel de sulfatos, y tanto el alcohol como los sulfatos tienen un efecto con curvatura que se aplanan en los valores altos.

Fuente del dataset

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). Wine Quality [Data set]. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/186/wine+quality>